

climAI Farm

Agricultura Inteligente com Dados Espaciais e IA

Integrante	RM
Henrique Sanches Silva	RM 570527
João Pedro Zavanela Andreu	RM 570231
Kayck Gabriel Evangelista da Silva	RM 572331
Luis Henrique Laurentino Boschi	RM 571352
Patrick Borges de Melo	RM 574030

QUERO CONCORRER

Tutor(a): Sabrina Otoni

Coord.: André Godoi

github.com/zjpza/fiap-gs-1

00 Resumo Executivo

O **climAI Farm** é uma plataforma de análise climática que combina dados históricos de satélites da **NASA POWER API** com leituras em tempo real da **OpenWeatherMap** e sensores físicos **ESP32** para entregar, via dashboard web interativo, previsões de temperatura e probabilidade de chuva para o dia seguinte - com foco em apoio à tomada de decisão na agricultura brasileira.

1.826
registros históricos

1.44°C
erro médio (MAE)

R2 0.71
precisão do modelo

0.611
AUC-ROC chuva

ilimitado
cidades suportadas

Proposta de valor

Produtores rurais de qualquer cidade do Brasil podem acessar previsão de temperatura amanhã com MAE de 1.44°C e alerta de probabilidade de chuva - com um ESP32 de ~R\$40,00 e conexão à internet.

01 Introdução

1.1 Contexto e Motivação

Satélites da NASA coletam dados climáticos globais diariamente com cobertura de cada município brasileiro. Esses dados, historicamente subutilizados pela agricultura familiar, são a principal matéria-prima do climAI Farm. Combinados com sensores IoT de baixo custo e Machine Learning, viabilizam previsões climáticas precisas e acessíveis para pequenos produtores.

1.2 Problema

Pergunta central da POC

Como democratizar o acesso a previsões climáticas precisas para produtores rurais utilizando dados de satélite da NASA, sensores IoT e IA?

1.3 Arquitetura da solução

Camada	Tecnologia	Função
01 - Coleta	NASA POWER API + OpenWeatherMap	Histórico 5 anos + tempo real
02 - IoT	ESP32 + DHT22 + BMP280	Sensor local temp./pressão
03 - Processamento	Python - Pandas - NumPy	EDA e feature engineering
04 - ML	scikit-learn	Regressão e classificação
05 - Dashboard	Streamlit - Plotly	Interface web interativa

Tabela 1 - Stack tecnológico do climAI Farm por camada de processamento

Análise Exploratória de Dados

2.1 Dataset

Dados coletados via NASA POWER API para Santo André/SP (lat -23.66, lon -46.54), período 2019-2023, totalizando **1.826 registros diários**. Pipeline de limpeza: substituição de valores -999 por NaN e interpolação linear para lacunas ≤ 3 dias (afeta menos de 0.5% do dataset).

2.2 Principais achados

Sazonalidade clara

Verão (dez-fev) acima de 23°C; inverno (jun-ago) abaixo de 18°C - padrão repetível em todos os 5 anos.

Chuvas concentradas

80% da precipitação ocorre entre outubro e março. Junho e julho têm média inferior a 3 mm/mês.

Alta correlação térmica

Pearson $r=0.91$ entre temperatura mínima e máxima - ambas são features úteis e complementares para o modelo ML.

ClimaSat — Painei EDA · Santo André / SP (2019-2023)




Figura 1 - Painei EDA: série histórica de temperatura com média móvel 30 dias, precipitação mensal acumulada, distribuição de frequência e scatter umidade × temperatura




Figura 2 - Heatmap de temperatura média (°C) por mês e ano. Leitura horizontal revela sazonalidade; vertical revela variação inter-anual




Figura 3 - Matriz de correlação de Pearson entre variáveis climáticas. Destaque para $r=0.91$ ($T.mín \times T.máx$) e $r=-0.38$ (umidade $\times$ temperatura)

03 Machine Learning

3.1 Estratégia e feature engineering

Dois modelos treinados para prever o dia seguinte (**T+1**). Separação treino/teste preservou ordem temporal (últimos 20% = teste) para evitar data leakage.

Diferenciais de feature engineering

- **Sazonalidade cíclica**: sin/cos do mês - continuidade entre dezembro e janeiro. - **Lags 1-7 dias**: o modelo aprende tendências de curto prazo. - **Médias móveis 7 e 14 dias**: suaviza ruído e captura tendência.

3.2 Resultados

Modelo	Tarefa	MAE	RMSE	R2	AUC-ROC
Ridge Regression	Temperatura T+1	1.44°C	1.80°C	0.710	-
Random Forest Reg.	Temperatura T+1	1.49°C	1.85°C	0.693	-
RF Classifier	Chuva T+1	-	-	-	0.611

Tabela 2 - Métricas avaliadas no conjunto de teste (20% final da série, shuffle=False)

Interpretação do R2=0.710

71% da variância da temperatura de amanhã é explicada pelas condições de hoje. Uma previsão ingênua ('amanhã = hoje') obteria R2~0.65 - o modelo agrega cerca de 6 pontos percentuais sobre o baseline.




Figura 4 - Painel ML: scatter previsto × real (Ridge e RF), série de previsão 90 dias, importância de features, matriz de confusão e curva ROC do classificador de chuva




Figura 5 - Temperatura prevista vs. real para Ridge Regression (esq.) e Random Forest Regressor (dir.). Concentração próxima à diagonal indica boa calibração.

04 Dashboard Interativo

4.1 Estrutura

Página	Conteúdo	Tecnologia
Visão Geral	KPIs ao vivo, série histórica, alertas de anomalia, ESP32	Plotly + OWM
Análise EDA	Heatmap, boxplot, histograma, correlações interativas	Plotly Express
Previsão ML	Sliders com dados reais, gauge temperatura e chuva	scikit-learn
Dados Brutos	Tabela filtrável, estatísticas, download CSV por cidade	Streamlit

Tabela 3 - Estrutura do dashboard climAI Farm

4.2 Funcionalidades diferenciais

Seletor de cidade global

Dropdown com 10 cidades brasileiras + campo livre geocodificado via OWM Geocoding API. Funciona para qualquer cidade do mundo.

Dados em tempo real

OpenWeatherMap atualiza a cada 5 minutos (st.cache_data TTL=300s). Linha pontilhada na série histórica indica temperatura atual.

Alertas automáticos

Compara leitura atual com normal climatológica do mês: verde (normal) - amarelo ($\geq 2^{\circ}\text{C}$) - vermelho ($\geq 4^{\circ}\text{C}$ fora do normal).

Sliders pré-preenchidos

Controles de ML preenchidos automaticamente com dados reais da cidade selecionada - tornando a predição contextualizada e imediata.

05 ESP32 + Sensores IoT

5.1 Hardware

Componente	GPIO	Medição	Precisão
DHT22	GPIO 4	Temperatura + Umidade	+/-0.5°C - +/-2%
BMP280	GPIO 21/22 (I2C)	Pressão + Altitude	+/-1 hPa - +/-1m
LED interno	GPIO 2	Status OK / Erro	1x OK - 3x Erro

Tabela 4 - Especificações do hardware da estação ESP32

5.2 Fluxo de dados

ESP32 lê os sensores a cada **5 segundos**, valida os valores e serializa em JSON via USB Serial (115200 baud). O script Python `climasat_serial_reader.py` lê o Serial, salva CSV incremental e serve endpoint HTTP em **localhost:8765** - consumido pelo dashboard com fallback automático para arquivo JSON.

Payload JSON gerado pelo ESP32:

```
{ "id": 42, "timestamp": 210, "temp": 22.4, "umidade": 76.8,
  "pressao": 1013.2, "altitude": 18.5, "status": "OK" }
```

Modo simulação automático

Se o ESP32 não estiver conectado, o sistema ativa gerador de dados sintéticos baseado nas normais climatológicas - o dashboard funciona completamente sem hardware.

06 Resultados e Status

Componente	Entregável	Status
NASA POWER API	1.826 registros históricos (2019-2023)	[OK]
EDA + Gráficos	6 visualizações geradas	[OK]
Ridge Regression	MAE=1.44°C - RMSE=1.80°C - R2=0.710	[OK]
RF Regressor	MAE=1.49°C - RMSE=1.85°C - R2=0.693	[OK]
RF Classifier	Acurácia=75.8% - AUC-ROC=0.611	[OK]
Dashboard Streamlit	4 páginas - cidade global - alertas	[OK]
OWM tempo real	Atualização 5 min - cache automático	[OK]
ESP32 + Sensores	DHT22 + BMP280 - JSON - modo simulação	[OK]
PDF de entrega	Este documento	[OK]
Vídeo YouTube	<=5 min - não listado - pendente link	[pendente]

Tabela 5 - Status completo de implementação do climAI Farm

07 Conclusão

O climAI Farm demonstra que dados espaciais da NASA têm aplicação direta na agricultura brasileira. A plataforma pode ser implantada por qualquer cooperativa rural com internet e um ESP32 de ~R\$40,00, democratizando previsões climáticas de qualidade para o campo.

Integração de disciplinas - Fases 3 e 4

Disciplina	Aplicação no projeto
Análise de Dados (Pandas/NumPy)	EDA completa, limpeza, feature engineering
Visualização (Matplotlib/Seaborn/Plotly)	6 gráficos EDA + 6 ML + dashboard interativo
Machine Learning introdutório	Ridge + Random Forest + métricas MAE/RMSE/R2/AUC
Python - estruturas e funções	5 módulos: EDA, ML, Dashboard, Serial, PDF
IoT / Sensores / ESP32	Firmware + DHT22 + BMP280 + serial/HTTP

Tabela 6 - Mapeamento de disciplinas aplicadas no climAI Farm

Próximos passos

- NDVI via Sentinel Hub - índice de vegetação por satélite
- Horizonte de 7 dias - previsão multistep com janela deslizante
- Deploy em nuvem - Streamlit Cloud (gratuito para POC)
- Sensor de umidade do solo - módulo capacitivo no ESP32
- Modelos por cultura - soja, milho e cana-de-açúcar

Referências e Links

Repositório GitHub:

<https://github.com/zjpza/fiap-gs-1>

Video demonstrativo (YouTube - nao listado):

<link_youtube_aqui>

NASA POWER API: <https://power.larc.nasa.gov/>

OpenWeatherMap API: <https://openweathermap.org/api>